

# 1. Fundamento para la Red Bayesiana

Para problemas de clasificación una de las posibles soluciones es utilizar una regresión logística, la cual es de la forma  $f(x) = \frac{L}{1+e^{-k(x-x_0)}}$ . En este caso utilizamos esta regresión logística de manera logarítmica, de esta forma nos queda de la siguiente manera:

$$\log\left(\frac{P(Y=1)}{1-(P(Y=1))}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 \quad (1)$$

En donde es directo despejar y llegar a que esto es:

$$P(Y=1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3)}} \quad (2)$$

También conocida como logit function, tenemos que  $\text{logit}(p_{ij}) = \log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$ .

Por otra parte con el teorema de bayes sabemos que:

$$P(Y^{DATA}|\beta) \rightarrow P(\beta|Y^{DATA}) = \frac{P(Y^{DATA}|\beta)P(\beta)}{P(Y^{DATA})} \quad (3)$$

De esta forma buscaremos valor para  $\beta$  como una función de probabilidad, los cuales pertenecerán a la solución de nuestro "logit function", por lo que partiendo de un algoritmo para encontrar estos beta's  $P(\beta|Y^{DATA})$  para finalmente utilizarlo de la manera  $P(Y^{DATA}|\beta)$ .

La cantidad de  $\beta$ 's se puede definir de manera arbitraria, por ejemplo podemos usar:

$$\text{logit}(P_{ij}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 \quad (4a)$$

$$\text{logit}(P_{ij}) = \beta_0 + \beta_1 X_1 + \beta_4 X_1^2 + \beta_2 X_2 + \beta_5 X_2^2 + \beta_3 X_3 + \beta_6 X_3^2 \quad (4b)$$

$$\text{logit}(P_{ij}) = \beta_0 + \beta_1 X_1 + \beta_4 X_1^2 + \beta_7 X_1^3 + \beta_2 X_2 + \beta_5 X_2^2 + \beta_8 X_2^3 + \beta_3 X_3 + \beta_6 X_3^2 + \beta_9 X_3^3 \quad (4c)$$

De esta forma tendremos a cada beta no como un número o un "peso" sino como un función de probabilidad:

$$\begin{aligned} \beta_i &\sim \mathcal{N}(\mu_{\beta_i}, \sigma_{\beta_i}^2) \\ \text{logit}(P_{ij}) &= \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 \\ Y_{ij} &= \text{Bernoulli}(P_{ij}) \end{aligned}$$

Siguiendo la idea mostrada en (3) también se puede probar otras formulaciones arbitrarias como la siguiente:

$$P(Y=1|\beta_1, \beta_2, \beta_3, PP, slope, humedad) \quad (5)$$

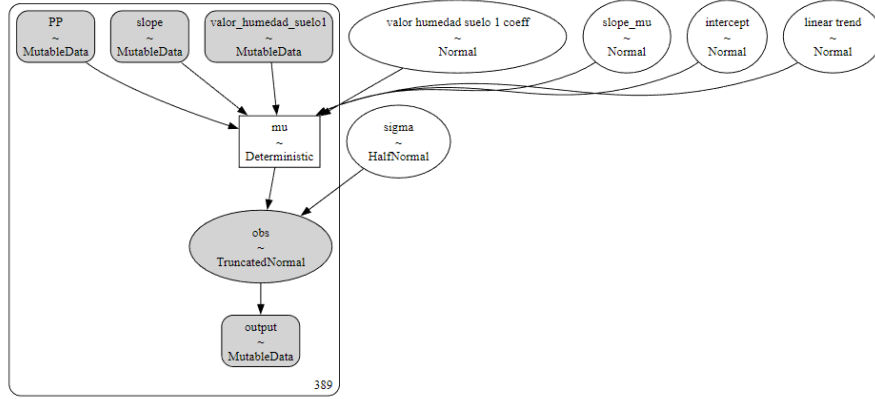


Figura 1: Nodos del modelo

## 2. Algoritmo Bayesiano y MCMC

Para encontrar  $P(\beta_n | y^{data})$  se computa  $\beta_1, \dots, \beta_n$ . Para el calculo se utiliza la computación llamada "Bayesian maximum likelihood":

$$\beta^{mode} = \arg \max_{\beta} \log[p(y^{data}|\beta)] + \sum_{i=1}^N \log[p_i(\beta_i)] \quad (6)$$

Cuando  $N \rightarrow \infty$  nuestro algoritmo aproxima  $p(\beta | y^{data})$  de manera perfecta

Así tenemos que:

$$f(\beta^{(Nx1)} | Y) = \frac{f(Y|\beta)f(\beta)}{f(Y)} \quad (7)$$

Lo que buscamos es la distribución posterior de  $\beta_i$ :

$$h(\beta_i | y) = \int f(\beta | y) d\beta, (i, \dots, N) \quad (8)$$

Donde el algoritmo Metropolis-Hastings (MCMC) nos va a permitir aproximar esta distribución de  $h(\beta_i | y)$  este algoritmo selecciona candidatos para  $\beta^{(r)}$ , y para el calculo de  $\beta^{mode}$  se utiliza el descenso de gradiente (no se mostrará aquí) de la formula (6).

No se va a mostrar cada paso del algoritmo ya que no es el objetivo, pero es importante ver la etapa 1 y 3 de este mismo. En la etapa 1 sabemos que se computa  $-\beta^{(1)} = \beta^*$ , ahora para  $\beta^r > 1$  se eligen candidatos para  $\beta^r$ :

$$\text{draw } x \text{ from } \beta^{(r-1)} + \kappa N(0, V) \quad (9)$$

Donde  $\kappa$  será un escalar, y el valor del factor  $\kappa N(0, V)$  será cada "salto" que da la distribución. Para la etapa 3 el algoritmo computa:

$$\beta^{(r)} = \begin{cases} \beta^{(r)}, & \text{si } \mu > \alpha \\ x, & \text{si } \mu < \alpha \end{cases}$$